文献引用格式：张乾君 .AI 大模型发展综述 [J]. 通信技术 ,2023,56(3):255-262.
doi:10.3969/j.issn.1002-0802.2023.03.001

AI 大模型发展综述 *

张乾君

（中国电子科技集团公司第十研究所，四川 成都 610036）

摘　要：AI 大模型作为当前最热门的技术领域，得到了广泛的关注。以谷歌的 BERT 和 OpenAI 的 GPT 为代表，模型的参数规模逐步提升至千亿甚至万亿级，训练数据量级也大幅提升，随之带来了模型能力的显著提高，掀起了国内外 AI 大模型的研究热潮。论述了 AI 大模型的发展概况，剖析了具有里程碑意义的各类算法模型，介绍了其依赖的核心技术和原理，评估了其存在的挑战和局限，最后讨论了未来 AI 大模型的发展趋势。

关键词：AI 大模型；Transformer；BERT；GPT；ERNIE

中图分类号：TP311　　**文献标识码：**A　　**文章编号：**1002-0802(2023)-03-0255-08

Survey on the Development of AI Large Model

ZHANG Qianjun

(No.10 Institute of CETC, Chengdu Sichuan 610036, China)

Abstract: As the hottest technology field in the current, AI large models received extensive attention. Taking Bert of Google and GPT of OpenAI as representatives, the parameter size of the model gradually increased to hundreds of billions or even trillions, and the training data scale also increased greatly, which brings about a significant improvement in model capability and triggers a research upsurge of AI large models at home and abroad. This paper gives an overview of the development of AI large models, analyzes various milestone algorithm models, introduces the core technologies and principles they rely on, evaluates their challenges and limitations, and finally discusses the development trends of AI large models in the future.

Keywords: AI large model; Transformer; BERT; GPT; ERNIE

0　引　言

当前，随着 AI 绘画、ChatGPT 的走红，人工智能生成内容（AI Generated Content，AIGC）成为行业热门话题，万众瞩目。AIGC 指的是一种通过 AI 技术来自动或辅助生成内容的生产方式，通过输入指令，人类让 AI 去完成冗杂的编写代码、绘图、建模、写作等任务，从而生成内容。AIGC 的发展离不开 AI 大模型底层技术的支撑。

AI 大模型也称人工智能预训练模型，它将海量数据导入具有亿量级参数的模型中，然后机器通过完成类似“完形填空”的任务，学习数据中蕴含的特征、结构，最终模型被训练成具有逻辑推理和分析能力的人工智能。近几年，AI 大模型俨然成为 AI 界“最耀眼的明星”，国内外科技巨头都不遗余力地布局 AI 大模型。国外，2018 年，谷歌提出了 3 亿参数基于变换器的双向编码器表示（Bidirectional Encoder Representation from Transformers，BERT）模型，惊艳四座；2019 年 2 月，OpenAI 推出了 15 亿参数的 GPT-2；紧接着 2020 年 6 月，OpenAI 推出了 1 750 亿参数的 GPT-3，直接将参数规模提

* **收稿日期：**2023-03-15；**修回日期：**2023-03-19　　Received date:2023-03-15; Revised date:2023-03-19

高到千亿级别；之后微软和英伟达联手发布了5 300 亿参数的 Megatron-Turing 自然语言生成模型（Megatron-Turing Natural Language Generative，MT-NLG）；2022 年 11 月底，Open AI 发布了 AI 对话模型 ChatGPT，一经推出，火爆全网。国内公司的 AI 大模型研发虽然比国外公司晚，但是发展却异常的迅速。2021 年 4 月，华为云联合循环智能发布盘古超大规模预训练语言模型，参数规模达 1 000 亿；2021 年 6 月，北京智源人工智能研究院发布了超大规模智能模型“悟道 2.0”，参数规模达到 1.75 万亿；2021 年 12 月，百度推出 ERNIE 3.0 Titan 模型，参数规模达 2 600 亿，同期，阿里巴巴达摩院的 M6 模型参数达到 10 万亿，将大模型参数直接提升了一个量级。

AI 大模型的发展，为各个领域带来了全新的面貌，意义重大。本文将尝试简单概述 AI 大模型发展概况，剖析具有里程碑意义的各类算法模型，介绍其依赖的核心技术和原理，评估其局限和面临的挑战，并讨论 AI 大模型未来的发展趋势。

1 AI 大模型发展概况

从模型演进来看，AI 大模型的发展先后经历了语言模型、预训练模型、大规模预训练模型、超大规模预训练模型几个阶段，其中大规模预训练模型和超大规模预训练模型一般出自工业界，参数量实现了万亿级的突破。

1.1 语言模型发展概况

语言模型（Language Model，LM）在自然语言处理中占有重要的地位，简单来说，它就是一串词序列的概率分布。具体来说，语言模型的作用是为一个长度为 m 的词序列确定一个概率分布 P，表示这段词序列存在的可能性，其计算公式为：

$$P(w_1,w_2,\cdots,w_m)=P(w_1)P(w_2|w_1)P(w_3|w_1,w_2)\cdots P(w_i|w_1,w_2,\cdots,w_{i-1})\cdots P(w_m|w_1,w_2,\cdots,w_{m-1}) \quad (1)$$

式中：$w_1,w_2,\cdots,w_m$ 为长度为 m 的词序列；$P(w_i)$ 为第 i 个词出现的概率；$P(w_i|w_1,w_2,\cdots,w_{i-1})$ 为在给定前 i-1 个词的情况下第 i 个词出现的概率。在实践中，如果文本的长度较长，$P(w_i|w_1,w_2,\cdots,w_{i-1})$ 的估算会非常困难，因此，研究者们提出使用一个简化模型——n 元模型（n-gram model）。在 n 元模型中估算条件概率时，只需要对当前词的前 n-1 个词进行计算，一般采用频率计数的比例来估算 n 元条件概率，计算式为：

$$P\left(w_i \mid w_1,w_2,\cdots,w_{i-1}\right)=P\left(w_i \mid w_{i-(n-1)},\cdots,w_{i-1}\right)$$
$$P\left(w_i \mid w_{i-(n-1)},\cdots,w_{i-1}\right)=\frac{count(w_{i-(n-1)},\cdots,w_{i-1},w_i)}{count(w_{i-(n-1)},\cdots,w_{i-1})} \quad (2)$$

当 n 较大时，会出现数据稀疏问题，导致估算结果不准确。当 n 取 1，2，3 时，n-gram model 又可分别称为 unigram、bigram、trigram，在百万词级别的语料中，一般也就用到三元模型。

为了缓解 n 元模型估算概率时遇到的数据稀疏问题，研究者们提出了神经网络语言模型，代表性工作是 Bengio 等人[1] 在 2003 年提出的神经网络语言模型（Neural Network Language Model，NNLM）。该语言模型使用了一个 3 层前馈神经网络[2] 来进行建模，其主要贡献在于将神经网络（Neural Network，NN）应用于 LM 中，通过为每个单词学习一个分布式表征来实现在连续空间上的建模，有效避免了数据稀疏的问题，其缺点在于只能处理定长的序列。随后，Mikolov 等人[3] 于 2010 年将递归神经网络（Recurrent Neural Network，RNN）应用于 LM 中，提出了 RNN 语言模型（RNNLM）[4]，该模型可以用于处理变长的序列，其主要缺点在于 RNN 训练过程中，可能会发生梯度消失或者梯度爆炸，导致训练速度变慢或使得参数值无穷大，无法解决长时依赖问题。为了解决这个问题，Sundermeyer 等人于 2012 年将长短时记忆网络（Long Short Term Memory，LSTM）[5] 引入到了 LM 中，提出了 LSTM-RNNLM[6]，除了记忆单元和 NN 的部分，LSTM-RNNLM 的架构几乎与 RNNLM 一样。至此，NNLM 逐渐成为主流的语言模型，并得到了迅速发展。

1.2 预训练语言模型发展概况

虽然 LSTM-RNNLM 能够解决序列的长时依赖问题，但是对于很长的序列，效果也不甚理想。为了更好地捕捉长距离信息，研究者们想要寻找到一种更强的语言模型方法，由此提出了以 transformer 结构[7] 为基础的预训练语言模型。

预训练语言模型是 NLP 的核心之一，语言模型本质上是根据上下文去预测下一个词是什么，不需要人工标注语料，这种无监督训练属性使其非常容易获取海量训练样本，并且训练好的语言模型包含丰富的语义知识，对于下游任务的效果会有非常明显的提升。

预训练语言模型要从词向量 Word2Vec 说起，

Word2Vec[8] 是 2013 年由 Mikolov 等人提出，用来获取原始文本的分布表示，其最大的缺点是词向量对于某一个词只能生成一个固定的向量，在实际情况中同一个单词在不同的语境里有不同的含义，因此无法结合语境上下文信息进行调整。为了解决这个问题，Peters 等人在 2018 年提出了嵌入语言模型（Embeddings from Language Models，ELMo）[9]。ELMo 模型采用了一个正向 LSTM 和一个反向 LSTM 联合训练的方式，每个单词在每层 LSTM 都会产生正向、反向两个嵌入（embedding），将每个单词所有层的 embedding 拼接在一起，得到这个词在这句话中结合了上下文语境信息的语义表达。此后，预训练语言模型成为 NLP 的核心任务之一，越来越多的研究者们开始进入该领域，先后出现了著名的 GPT 系列模型、BERT 系列模型等，在预训练模型史上具有里程碑意义。

1.2.1　GPT 系列模型

2018 年，OpenAI 公司提出了 GPT-1 模型 [10]，其主要包括无监督预训练和有监督微调两个阶段。相比 ELMo，GPT-1 真正意义上实现了预训练 – 微调（pretrain-finetune）的框架，不再需要将模型中的 embedding 取出来，直接把预训练好的模型在下游任务上微调（finetune），对于不同任务采用不同的输入或输出层改造，让下游任务更贴近上游预训练。对于下游任务的训练，虽然 GPT-1 往往只需要简单的微调便能取得非常好的效果，但在未经微调的任务上其泛化能力远远低于经过微调的有监督任务，说明了 GPT-1 只是一个简单的领域专家，而非通用的语言学家。

针对 GPT-1 模型不具有通用性的问题，2019 年，OpenAI 提出了 GPT-2 模型 [11]，他们认为任何一个有监督 NLP 任务，都可以看成语言模型的一个子集，只要预训练语言模型的容量足够大，理论上就能解决任何 NLP 任务。任何 NLP 任务都可以表示成 $p(output|input,task)$ 的形式，语言模型就是无监督的多任务学习。因此，GPT-2 的核心就是提升模型的容量和数据多样性，让语言模型能够达到解决任何任务的程度。

2020 年，OpenAI 在 GPT-2 的基础上进一步提出了 GPT-3 模型 [12]，他们认为人类可以仅通过个别的例子或者一个简单的任务说明，就可以实现一个新的语言任务。因此，对于所有的 NLP 任务，GPT-3 在应用时不进行梯度更新或者微调，仅使用任务说明和个别示例与模型进行文本交互，同时，GPT-3 也不像 GPT-2 追求零样本学习（Zero-Shot learning）。GPT-3 参数量达到 1 750 亿，在许多 NLP 的数据集上都有很好的表现。在各种场景中，GPT-3 可以写文章、故事，还可以进行多轮对话、写代码、做表格、生成图标等，具有非常可观的商业价值。

虽然 GPT-3 模型拥有了强大的能力，但是由于其训练语料来自网络，在文本生成时可能会生产出错误的、恶意冒犯的，甚至是带有攻击性的“有毒”文本。为了改进 GPT-3 模型，OpenAI 提出了人类反馈强化学习（Reinforcement Learning from Human Feedback，RLHF）技术 [13]，用于矫正 GPT-3 的学习行为。通过这样的方式，模型得到对于用户来说更安全、更有用且更符合人类想法的结果。火爆全网的 ChatGPT 就是由该改进模型提供支持，使其能理解人类不同指令的含义，处理多元化的主题任务，既可以回答用户后续问题，又可以质疑错误问题和拒绝不适当的请求，功能无比强大。

1.2.2　BERT 系列模型

另一类著名的预训练语言模型是 BERT 系列模型，2018 年，Google 提出了该模型 [14]，它主要有两大创新：一是借助 Transformer 学习双向表示，将多个 Transformer 编码器（Transformer encoder）堆叠在一起，其中，BERT base 使用的是 12 层的 encoder，BERT large 使用的是 24 层的 encoder，Transformer 是一种深度学习组件，旨在通过在左右上下文中共有的条件来预先训练来自无标号文本的深度双向表示；二是在预训练方法的基础上，使用掩码语言模型（Masked Language Model，MLM）和下一句预测（Next Sentence Prediction，NSP）分别捕捉词语和句子级别的语义表征。因此，经过预先训练的 BERT 模型只需一个额外的输出层就可以进行微调，从而为各种自然语言处理任务生成最新模型。BERT 模型成功在 11 项 NLP 任务中取得目前最高水平（state of the art）的结果，为 NLP 发展史上里程碑式的成就。此后，在 BERT 模型基础上，研究者们又做了大量的改进。

2019 年，Liu 等人提出了强力优化的 BERT 模型（A Robustly Optimized BERT Pretraining Approach，RoBERTa）[15]，对 BERT 模型的训练方式进行了对比实验和分析，并基于此总结了能够提升 BERT 效果的训练方法，例如动态 mask 机制、移除 NSP 任务、

Batch size 更大、训练时间更长、训练数据更多、训练序列更长等。

2019 年，清华大学的 Zhang 等人提出了 ERNIE（THU）模型[16]，其主要的贡献在于把知识图谱融合到预训练语言模型的过程中。具体地，对于文本中的实体，在知识库中找到对应的实体，利用 transE 进行表示之后，在 BERT 的文本编码器（text encoder）之上再加一层知识编码器（knowledge encoder）。

2019 年，百度公司的 Sun 等人提出百度版的 ERNIE（Baidu）模型[17]，主要针对 BERT 在中文 NLP 任务中表现不够好的问题提出了改进，核心改进点在于在训练的过程中加入了实体级屏蔽和短语级屏蔽。此外，作者还在预训练中加入了对话语料，结果显示效果也会有一些提高，这指明了一个方向，在预训练阶段，除了修改模型、目标函数以外，选择高质量、特定领域的语料也是可行的方向。

2020 年，Lan 等人提出了精简的 BERT 模型（A Lite BERT，ALBERT）[18]，它是一个轻量级的 BERT 模型，以此降低 BERT 的运行开销。为了减少 BERT 资源开销，该文主要提出了两个优化：因式分解嵌入参数（Factorized embedding parameterization）、跨层参数共享（Cross-layer parameter sharing）。其中因式分解嵌入参数将嵌入矩阵分解为两个小的矩阵，跨层参数共享是让跨 ALBERT 的每一层共享 transformer 权重，这将显著减少参数。除了上述两个降低 BERT 运行开销的优化外，ALBERT 还提出了句间连贯性损失（inter-sentence coherence loss）这一新的优化目标。

2020 年，Clark 等人提出了 ELECTRA 模型（Efficiently Learning an Encoder that Classifies Token Replacements Accurately）[19]，该文的核心思路采用了 GAN 的思路。模型包括一个生成器和一个判别器。生成器通常是一个小的 MLM，可以学习预测被 mask token 的原始单词。判别器被训练以鉴别输入 token 是否被生成器替换。通过对抗学习的方式，让模型从文本中提取信息的能力增强。

1.2.3 混合预训练模型

ElMo、GPT 和 BERT 作为经典模型，各有千秋，在多个领域取得了显著的成效，后续研究者们又提出了基于几者的混合改进模型，这里主要介绍 UniLM、XLNet、BART 这 3 种。

2019 年，Dong 等人提出了统一语言模型（Unified Language Model，UniLM）[20]，该模型融合了 EMLo、BERT、GPT-3 这 3 种语言模型的优化目标，其最大的创新在于通过精巧控制掩码（mask）的方式，实现了在一个模型中同时优化 3 种语言模型。

2019 年，Yang 等人提出了广义自回归语义理解预训练模型（Generalized Autoregressive Pretraining for Language Understanding，XLNet）[21]，文中将无监督语言模型分成两类，一类是自回归模型，如 GPT、ELMo 这种使用单向语言模型建模概率分布的方法；另一类是自编码模型，如 BERT 这种预测句子中 token 的方法。XLNet 融合了自回归模型和自编码模型各自的优点，既能建模概率密度，适用于文本生成类任务，又能充分使用双向上下文信息。

2019 年，Lewis 等人提出了双向自回归 Transformers 模型（Bidirectional and Auto-Regressive Transformers，BART）[22]，该模型融合了 GPT 和 BERT 模型的优点，主要包括两个训练阶段：首先，将原始输入文本使用某噪声函数，得到被破坏的文本，这个文本会输入到类似 Bert 的编码器中，得到被破坏文本的编码；其次，使用一个类似 GPT 的结构，采用自回归的方式还原出被破坏之前的文本。

1.3 工业大模型的发展概况

在工业界，各大巨头也开始发展自己的大模型，自 2018 年以来，国内外超大规模预训练模型参数指标不断创出新高，谷歌、百度、微软等国内外科技巨头纷纷投入大量人力、财力，相继推出各自的巨量模型。

在国外，超大规模预训练模型起步于 2018 年，2021 年进入“军备竞赛”阶段。除了上文提到的 Google 的 BERT 模型、OpenAI 的 GPT 系列模型，2019 年，英伟达还推出了 83 亿参数的 Megatron-LM，谷歌推出了 110 亿参数的 T5，微软推出了 170 亿参数的图灵 Turing-NLG；2020 年 10 月，微软和英伟达在联手发布了 5 300 亿参数的 Megatron-Turing 自然语言生成模型（MT-NLG）；2021 年，谷歌推出了 Switch Transformer 模型，以高达 1.6 万亿的参数量成为史上首个万亿级语言模型；2021 年 12 月，谷歌还提出了 1.2 万亿参数的通用稀疏语言模型 GLaM，在 7 项小样本学习领域的性能超过 GPT-3。

在国内，超大模型研发厚积薄发，虽然国内超

大模型研发比国外公司晚，但是发展却异常的迅速。2021 年 4 月，华为云联合循环智能发布盘古 NLP 超大规模预训练语言模型，参数规模达 1 000 亿，并联合北京大学发布盘古 α 超大规模预训练模型，参数规模达 2 000 亿；2021 年 4 月，阿里达摩院发布 270 亿参数的中文预训练语言模型 PLUG，并联合清华大学发布参数规模达到 1 000 亿的中文多模态预训练模型 M6；2021 年 6 月，北京智源人工智能研究院发布了超大规模智能模型“悟道 2.0”，参数达到 1.75 万亿，成为当时全球最大的预训练模型；2021 年 7 月，百度推出 ERNIE 3.0 知识增强大模型，参数规模达到百亿；2021 年 10 月，浪潮发布约 2 500 亿的超大规模预训练模型“源 1.0”；2021 年 12 月，百度推出 ERNIE 3.0 Titan 模型，参数规模达 2 600 亿；而 2021 年 11 月，达摩院的 M6 模型参数跃迁至 10 万亿，将大模型参数直接提升了一个量级。

到 2023 年，大模型继续火热，从最开始的自然语言处理领域，如今已逐渐拓展到视觉、决策领域，甚至用于解决蛋白质预测、航天等领域的重大科学问题，谷歌、Meta、百度等大厂都有相应的成果。一时间，参数量低于 1 亿的 AI 模型已经没有声量。

2　AI 大模型核心技术

AI 大模型的成功是多类技术的积累，但其中最为核心的是自注意力机制和 Google 在 2017 年提出的 Transformer 架构，BERT、GPT 都是基于它们相继提出的。

2.1　自注意力机制

自注意力机制（Self-Attention），又称内部注意力机制，顾名思义，是一种将单个序列的不同位置关联起来以计算同一序列表示的注意力机制。Self-Attention 的架构如图 1 所示，其注意力计算公式为：

$$Attention(\boldsymbol{Q},\boldsymbol{K},\boldsymbol{V}) = soft\max\left(\frac{\boldsymbol{Q}\boldsymbol{K}^{\mathrm{T}}}{\sqrt{d_k}}\right)\boldsymbol{V} \quad (3)$$

式（3）中的 $\boldsymbol{Q}$，$\boldsymbol{K}$，$\boldsymbol{V}$ 的表示如图 2 所示，可以看出其来源都是 $\boldsymbol{X}$ 与矩阵的乘积，本质上都是 $\boldsymbol{X}$ 的线性变换，这也是为什么该技术被叫作自注意力机制。

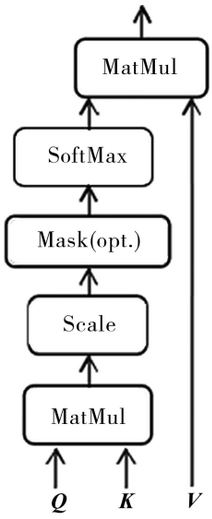

图 1　Self-Attention 架构

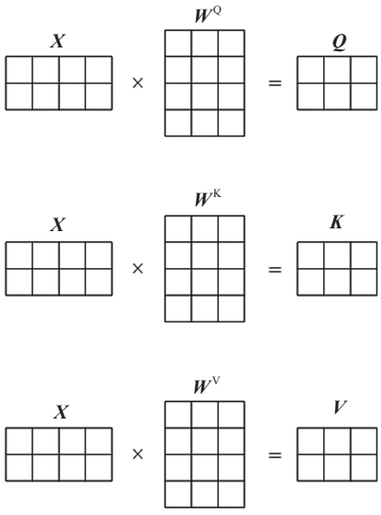

图 2　自注意力机制中 $\boldsymbol{Q}$，$\boldsymbol{K}$，$\boldsymbol{V}$ 的计算表达

通过引入自注意力机制，可以捕获同一个句子中单词之间的一些句法特征或者语义特征，同时也更容易捕获句子中长距离的相互依赖的特征，对于增加计算的并行性也有直接帮助作用。这些因素使得自注意力机制逐渐被广泛使用。

2.2　Transformer

Transformer 是 Google 在 2017 年提出的重要架构，其中自注意力机制是它重要的组成部分。Transformer 架构如图 3 所示。

Transformer 模型结构由多个编码器和解码器叠加组成，其中编码器和解码器均是由基于自注意力的模块叠加而成的，其输入分别是源序列和目标序列的嵌入表示加上位置编码（positional encoding）。

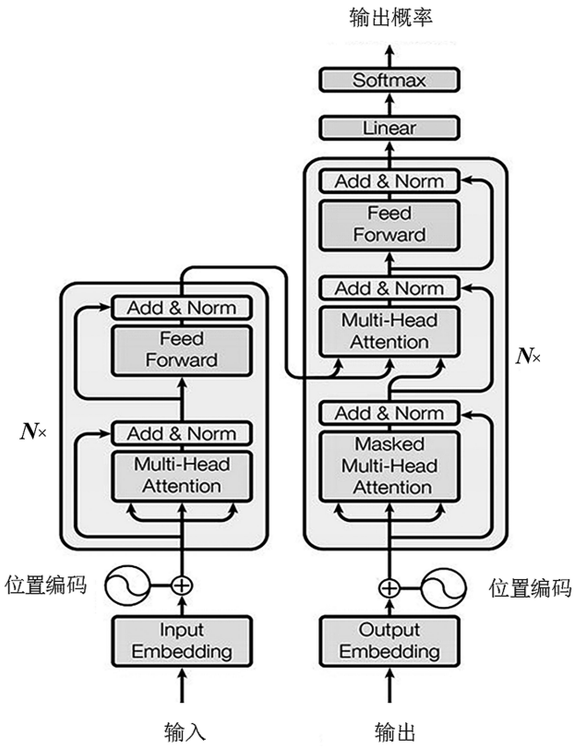

图 3 Transformer 架构

编码器有两个子层：第 1 个子层是多头自注意力（multi-head self-attention）层，其利用自注意力学习源句内部的关系；第 2 个子层是基于位置的前馈网络（positionwise feed forward）层，是简单的全连接网络，对每个位置的向量分别进行相同的操作，包括两个线性变换和一个 ReLU 激活函数。每个子层都采用了残差连接（residual connection），紧接着进行应用层规范化（layer normalization）。这里的编码过程是并行计算的，相比于原来的编码器 - 解码器模型，极大地提高了效率。

解码器中有 3 个子层，分别为两个多头注意力（multi-head attention）层和基于位置的前馈网络，和编码器一样，层中同样使用了残差链接和层规范化。最下面的掩码多头注意力（masked multi-head attention）层利用自注意力学习目标句内部的关系，此外，由于每个位置只能考虑该位置之前的所有位置，因此这里使用掩蔽保留了自回归属性，确保预测仅依赖于已生成的输出词元。之后，将掩码多头注意力层的输出和编码器的结果一起输入到第 2 个多头自注意力（multi-head attention）层，这个注意力层并不是自注意力，而是编码—解码（encoder-decoder）注意力层，用来学习源句与目标句之间的关系。

Transformer 架构有效解决了长时依赖问题，增大了模型的并行性，在多个任务中取得了很好的效果，在学术界、工业界被广泛使用，为 GPT、BERT 模型的提出奠定了基础。

3 存在的局限及未来趋势

3.1 局 限

AI 大模型的发展为各个领域带来了全新的面貌，尤其是 NLP 领域，可谓日新月异，但是 AI 大模型的发展依然面临很大的挑战。

（1）大模型的可解释性较为薄弱。由于大模型采用了深度神经网络架构，模型参数往往过亿级别，因此数据在模型中的处理过程难以追踪，也很难获得对模型推理结果的有效解释。

（2）更大的模型带来了更高的训练成本，包括高科技人才的智力支出、大数据和大算力所需的经济成本，此外，还有不可忽视的环境影响。

（3）越来越大的模型所带来的效用提升正在缩小。人们发现，当模型参数规模增长 10 倍时，得到的性能提升往往不到 10 个百分点。

（4）大模型带来了伦理方面的风险。由于大模型的训练需要的数据极为庞大，因此靠人工进行收集和检查并不现实，一般都采用机器自动进行训练数据的收集，导致训练集中可能存在粗俗、暴力、色情等内容。

（5）大模型的广泛应用也会带来一些负面的社会效应。据预测，未来大部分大学生会使用大模型生成的文本来代替本应由他们自己撰写的作业，而与之对抗的检测手段则很难真正发挥作用。

因此，AI 大模型下一步如何发展，也成为研究者共同关注的问题。

3.2 趋 势

在 AI 大模型发展中，未来的发展方向又在哪儿呢？阿里达摩院在发布的报告 [23] 中表示，未来大模型的参数规模发展将进入冷静期，大模型与相关联的小模型的协同发展将是未来的发展方向。其中，大模型沉淀的知识与认知推理能力向小模型输出；小模型基于大模型的基础叠加垂直场景的感知、认知、决策、执行能力，再将执行与学习的结果反馈给大模型，让大模型的知识与能力持续进化，形成一套有机循环的智能系统。参与者越多，模型进化的速度也越快。

百度研究院发布的《2022 年十大科技趋势预

测》[24] 中提到，超大规模预训练模型将呈现知识增强、跨模态统一建模、多学习方式共同演进的趋势，并逐渐实用化，而非盲目增加参数规模的“军备竞赛”发展模式。大模型研发方向将转向“实用化”，大模型的效果、通用性、泛化性、可解释性和运行效率将持续提升，应用门槛不断降低，在多场景广泛落地。

智源研究院在发布的《超大规模智能模型产业发展报告》[25] 中提出，未来将从技术、产业、伦理等方面出发，发展更加绿色环保的模型技术，推广低门槛的大规模开发和使用工具，如数据收集、处理、标注等数据工具，模型微调、剪枝、蒸馏、雅俗等模型工具，促进大模型的产业落地。

总的来说，未来 AI 大模型的发展趋势基本会从实用性角度朝着产业落地方向发展。

4 结　语

AI 大模型作为当前最热门的研究对象，在各个领域得到了广泛的研究和关注，其先后经历了语言模型、预训练模型、大规模预训练模型、超大规模预训练模型几个阶段，参数量实现了万亿级的突破。自 2018 年以来，国内外超大规模预训练模型参数指标不断创出新高，谷歌、百度、微软等国内外科技巨头纷纷投入大量人力、财力，相继推出各自的巨量模型。然而，在大模型获得广泛应用，为各个领域带来崭新面貌的同时，也面临着可解释性差、训练成本高、存在伦理风险等挑战。

未来 AI 大模型的参数规模发展将有可能进入冷静期，相关研究也在让下游任务更加去适配大模型，以此最大限度发挥大模型的能力。同时，关于 AI 大模型的产业落地相关研究也会逐步增多，数据采集、标注、模型压缩、剪枝、蒸馏等工具将被开发并广泛推广使用。

总体而言，现在 AI 大模型的研究，包括模型结构的演进和落地仍处在探索阶段，人们的持续探索正在不断扩大对 AI 大模型的认知边界。

参考文献：

[1] BENGIO Y,SCHWENK H,SENÉCAL J S,et al.A neural probabilistic language models[M]//HOLMES DE,JAIN L C.Innovations in Machine Learning.Berlin/Heidelberg:Springer-Verlag,2006:137-186.

[2] SCHMIDHUBER J.Deep learning in neural networks:An overview[J].Neural Networks:the Official Journal of the International Neural Network Society,2015,61:85-117.

[3] MASUMURA R,ASAMI T,OBA T,et al.Latent words recurrent neural network language models[C]//Sixteenth Annual Conference of the International Speech Communication Association,2015:2380-2384.

[4] MIKOLOV T,KOMBRINK S,DEORAS A,et al.RNNLM - recurrent neural network language modeling toolkit[C]//IEEE Automatic Speech Recognition and Understanding Workshop,2011:1-4.

[5] HOCHREITER S,SCHMIDHUBER J.Long short-term memory[J].Neural Computation,1997,9(8):1735-1780.

[6] SUNDERMEYER M,SCHLÜTER R,NEY H.LSTM neural networks for language modeling[C]//Interspeech 2012,2012:194-197.

[7] VASWANI A,SHAZEER N,PARMAR N,et al.Attention is all You need[J/OL].arXiv,2017:1706.03762[2022-02-03].https://arxiv.org/abs/1706.03762.

[8] MIKOLOV T,SUTSKEVER I,KAI C,et al.Distributed representations of words and phrases and their compositionality[C]//Proceedings of the 26th International Conference on Neural Information Processing Systems,2013:3111-3119.

[9] PETERS M E,NEUMANN M,IYYER M,et al.Deep contextualized word representations[J/OL].arXiv,2018:1802.05365[2022-02-03].https://arxiv.org/abs/1802.05365.

[10] RADFORD A,NARASIMHAN K.Improving language understanding by generative pre-training[EB/OL].[2023-02-03].https://www.cs.ubc.ca/~amuham01/LING530/papers/radford2018improving.pdf.

[11] RADFORD A,WU J,CHILD R,et al.Language models are unsupervised multitask learners[J].OpenAI blog,2019,1(8):9.

[12] BROWN T,MANN B,RYDER N,et al.Language models are few-shot learners[J].Advances in neural information processing systems,2020,33:1877-1901.

[13] CHRISTIANO P,LEIKE J,BROWN T B,et al.Deep reinforcement learning from human preferences[J/OL].arXiv,2017:1706.03741[2022-02-03].https://arxiv.org/abs/1706.03741.

[14] DEVLIN J,CHANG M,LEE K,et al.BERT:Pre-training of deep bidirectional transformers for language understanding[J/OL].arXiv,2018:1810.04805[2022-02-21].https://arxiv.org/abs/1810.04805.

[15] LIU Y,OTT M,GOYAL N,et al.RoBERTa:A robustly

optimized BERT pretraining approach[J/OL].arXiv, 2019:1907.11692[2022-02-21].https://arxiv.org/abs/1907.11692.

[16] ZHANG Z,HAN X,LIU Z,et al.ERNIE:Enhanced language representation with informative entitie[J/OL].arXiv,2019:1905.07129[2022-02-21].https://arxiv.org/abs/1905.07129.

[17] SUN Y,WANG S,LI Y,et al.ERNIE:Enhanced representation through knowledge integration[J/OL].arXiv,2019:1904.09223[2022-02-21].https://arxiv.org/abs/1904.09223.

[18] LAN Z,CHEN M,GOODMAN S,et al.ALBERT: A Lite BERT for self-supervised learning of language representations[C]//International Conference on Learning Representations,2020:1-17.

[19] CLARK K,LUONG M T,LE Q V,et al.ELECTRA:Pre-training text encoders as discriminators rather than generator[J/OL].arXiv,2020:2003.10555[2022-02-24].https://arxiv.org/abs/2003.10555.

[20] DONG L,YANG N,WANG W,et al.Unified language model pre-training for natural language understanding and generation[J/OL].arXiv,2019:1905.03197[2022-02-24].https://arxiv.org/abs/1905.03197.

[21] YANG Z,DAI Z,YANG Y,et al.XLNet:Generalized autoregressive pretraining for language understanding[J/OL].arXiv,2019:1906.08237[2022-02-24].https://arxiv.org/abs/1906.08237.

[22] LEWIS M,LIU Y H,GOYAL N,et al.BART:Denoising sequence-to-sequence pre-training for natural language generation,translation,and comprehension[J/OL].arXiv,2019:1910.13461[2022-02-24].https://arxiv.org/abs/1910.13461.

[23] 阿里巴巴达摩院 .2023 十大科技趋势 [EB/OL].(2023-01-11)[2023-02-24].https://files.alicdn.com/tpsservice/9b8b05280c05294f158bdb0dee61f78b.pdf.

[24] 百度研究院 .2023 年十大科技趋势预测 [EB/OL].(2023-01-05)[2023-01-15].https://mp.weixin.qq.com/s/jEiqFTLh5E3h_2h7RP7ClA.

[25] 北京智源人工智能研究院 . 超大规模智能模型产业发展报告 [R/OL].(2021-09-24)[2022-02-24].https://baai.org/l/MdRePort.

作者简介：

张乾君（1986—），女，博士，高级工程师，主要研究方向为机器学习、神经网络和智能情报。